

Reconstrucción de Imágenes Satelitales del Producto ACMF del GOES-16 mediante Redes LSTM

Juan Camilo Guavita¹, Germán Santiago Romero², and Manuel Lozano Pantoja³

¹Universidad de los Andes, Bogotá, Colombia, jc.guavita@uniandes.edu.co

²Universidad de los Andes, Bogotá, Colombia, gs.romeroml@uniandes.edu.co

³Universidad de los Andes, Bogotá, Colombia, ms.lozano@uniandes.edu.co

I. INTRODUCCIÓN

El uso de imágenes satelitales y los modelos de aprendizaje profundo se están utilizando de manera conjunta para estudiar la evolución de eventos climáticos. Desde predecir las etapas de erupción de volcanes en diferentes ambientes hasta la predicción en la fuerza y dirección de tormentas y huracanes, los algoritmos de aprendizaje profundo utilizan los datos medidos por satélites para diferentes tipos de aplicaciones. En concreto, la información adquirida del satélite GOES-16 se puede utilizar para predecir la irradiancia solar, con el objetivo de estimar de manera efectiva la producción de energía eléctrica en plantas solares en un horizonte de tiempo finito.

Actualmente, existen algoritmos clásicos de estimación de irradiación solar que utilizan la información suministrada por instrumentos de medición instalados directamente en el área del parque solar. Sin embargo, las dificultades inherentes a la calibración de estos equipos, así como el control de calidad de la información, plantean la posibilidad de diversificar las fuentes de información para la estimación de la irradiancia.

Dentro de las opciones disponibles, la información del satélite geoestacionario GOES-16 surge como una alternativa atractiva para la predicción de irradiación solar, en gran parte debido al avance en la adquisición de información de manera remota en instantes de tiempo determinados (GOES-16 adquiere información cada 10 minutos).

Estos avances han permitido la recolección y almacenamiento de datos sobre variables físicas y ambientales con una alta resolución temporal y espacial, lo que mejora la precisión en el monitoreo de fenómenos meteorológicos a nivel global y, específicamente, en regiones con alta exposición solar. Sin embargo, la información satelital no es recopilada de manera perfecta, existiendo errores en la captura de la información o inexistencia de esta en un instante de tiempo determinado generando una discontinuidad.

Esta discontinuidad en la información, implica desconocimiento temporal en el comportamiento de la variable estudiada, en algunos casos por instantes de tiempo seguidos. Cada instante de tiempo almacena información valiosa sobre algún fenómeno meteorológico, por lo que se hace necesario proponer algoritmos que permitan reconstruir esta información faltante. En este trabajo se expone un algoritmo que permite reconstruir estas imágenes faltantes, teniendo en cuenta el

progreso secuencial de las imágenes anteriores, siendo un algoritmo con memoria temporal.

II. METODOLOGÍA

II-A. Fuentes de Información

La principal fuente de datos para este proyecto es el satélite GOES-16, que opera en una órbita geoestacionaria sobre el hemisferio occidental, proporcionando observaciones de alta resolución en diversas bandas espectrales con una frecuencia de actualización de hasta 10 minutos. El sensor ABI (Advanced Baseline Imager) del GOES-16 es capaz de capturar información en 16 bandas espectrales, con resoluciones espaciales que van desde 0.5 km a 2 km y un espectro infrarrojo entre 0.47 y 13.3 μm . Estas características lo convierten en una herramienta esencial para el monitoreo climático y ambiental.

En este proyecto, se utilizan los datos del producto ACMF (Clear Sky Mask), que proveen información sobre la cobertura de nubes y otras condiciones del cielo. Este producto es fundamental para capturar las características de la zona de interés, específicamente el parque solar El Paso, ubicado en el departamento del Cesar, Colombia, en el cual se está realizando un trabajo de aplicación de redes para la estimación de irradiación solar que se puede llegar a generar en un rango de tiempo determinado. La Figura 1 muestra un ejemplo representativo de las imágenes generadas a partir del producto ACMF.




Figura 1. Imagen producto ACMF en la región de interés

Dado el extenso alcance geográfico de los datos capturados por el satélite, es necesario un preprocesamiento para filtrar y

enfocar únicamente la región de interés. Este proceso asegura que las imágenes y las predicciones estén directamente relacionadas con el contexto específico del parque solar El Paso, maximizando la relevancia de las predicciones generadas.

II-B. Preparación y manejo de la Información

El flujo de trabajo general del proceso de modelado y predicción se ilustra en la Figura 2. Este diagrama resume los pasos principales, que se detallan a continuación.

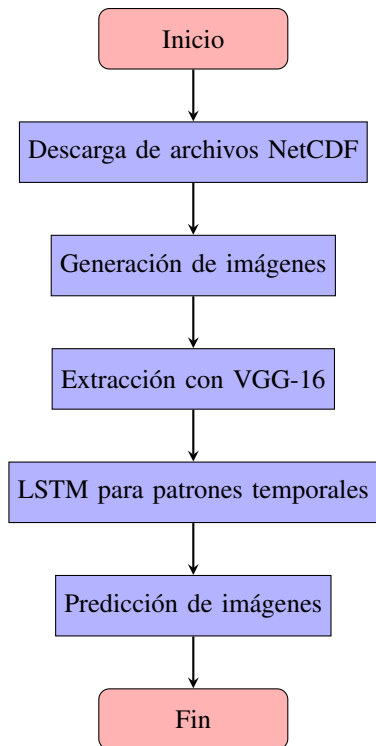


Figura 2. Diagrama de flujo del proceso de modelado y predicción.

1. Descarga de documentos NetCDF correspondientes al periodo de validación

Para acceder a los datos del satélite GOES-16, se establece una conexión con el bucket de Amazon Web Services (AWS), donde se alojan grandes volúmenes de información satelital en formato NetCDF (.nc). Utilizando la librería GOES en Python, este proceso automatiza la identificación y descarga de los archivos basados en parámetros específicos, como el rango de fechas y el producto deseado (en este caso, ACMF).

La librería facilita la interacción con AWS, eliminando la necesidad de procedimientos manuales complejos y garantizando la consistencia en la selección de datos. Cada archivo descargado incluye variables geoespaciales, como coordenadas latitudinales y longitudinales, y datos espectrales relacionados con la cobertura de nubes y condiciones del cielo. Estos archivos se organizan sistemáticamente en carpetas según las fechas y áreas de interés, listas para ser procesadas en las etapas siguientes.

Un aspecto crítico de este paso es la validación de los datos descargados. Se verifican atributos como

integridad del archivo y correspondencia con las fechas solicitadas, descartando datos corruptos o incompletos para identificar posibles candidatos para generar las imágenes con la red.

2. Generación de imágenes satelitales

El proceso para convertir los datos del producto ACMF del satélite GOES-16 en imágenes satelitales es un paso fundamental en la preparación de los datos. Este procedimiento permite visualizar las características atmosféricas registradas por el satélite en un formato gráfico que facilita el análisis y la integración con modelos de aprendizaje profundo.

El método utiliza archivos en formato .nc proporcionados por el satélite, que contienen variables geoespaciales y espectrales correspondientes a las condiciones meteorológicas capturadas. A partir de estos archivos, se generan imágenes en formato .jpg, organizadas cronológicamente con base en marcas de tiempo derivadas de los datos. La representación gráfica incluye la clasificación de la máscara de nubosidad en categorías específicas, según la Tabla I. Estas imágenes se generan en formato PNG o JPG y se etiquetan con marcas de tiempo derivadas de los archivos NetCDF para mantener una correspondencia clara entre los datos originales y las imágenes procesadas.

Tabla I
RANGOS Y CATEGORÍAS DEL PRODUCTO ACMF DEL GOES-16.

Variable	Valor/Rango	Descripción
Cloud Mask	0	Clear (Despejado)
	1	Probably Clear (Probablemente despejado)
	2	Probably Cloudy (Probablemente nublado)
	3	Cloudy (Nublado)
Confidence Levels	0	No determinado
	1	Baja confianza
	2	Moderada confianza
	3	Alta confianza
Cloud Type (Opcional)	Enteros específicos	Clasificación de tipos de nubes, como cúmulos o cirros
Aerosol Detection	-	Presencia de aerosoles (si aplica)

El proceso, que incluye desde la carga y el filtrado de datos hasta la generación y almacenamiento de las imágenes, se detalla a continuación:

- Filtrado por rango de fechas:** Los archivos .nc se organizan en una lista y se filtran mediante un patrón de expresión regular que extrae la estampa de tiempo del nombre del archivo (e.g., `YYYYMMDDHHMMSS`). Solo los archivos cuya estampa de tiempo se encuentra dentro del rango de fechas especificado son procesados, garantizando que solo los datos relevantes sean considerados.
- Carga y extracción de datos relevantes:** Para cada archivo en el rango de fechas seleccionado, el script utiliza la biblioteca `xarray` para abrir el archivo y seleccionar un subconjunto geoespacial

de los datos mediante las coordenadas especificadas. Esto permite extraer únicamente la región de interés, reduciendo la carga computacional y optimizando el uso de memoria.

- c) **Concatenación de datasets:** Los datos extraídos de múltiples archivos son concatenados en un único objeto `xarray.Dataset`, estandarizando las marcas de tiempo a intervalos de 10 minutos. Este paso asegura la coherencia temporal de las imágenes generadas, un aspecto crucial para el análisis de patrones meteorológicos.
- d) **Visualización y generación de imágenes:** Para cada estampa de tiempo en el conjunto de datos, se genera una representación gráfica de la variable ACM (máscara de nubosidad). El gráfico resultante se guarda como una imagen en formato `.jpg`, utilizando la marca de tiempo como parte del nombre del archivo (e.g., `ACMF_YYYYMMDD_HHMMSS.jpg`). Las imágenes se almacenan en una carpeta de salida especificada, lo que facilita su integración con etapas posteriores del flujo de trabajo.
- e) **Manejo de memoria y recursos:** Para optimizar el uso de memoria, las figuras generadas se cierran inmediatamente después de ser guardadas. Esto asegura que el proceso sea eficiente incluso cuando se trabaja con grandes volúmenes de datos.

Este proceso automatizado permite transformar los datos en bruto en un conjunto de imágenes organizadas, listas para ser utilizadas en modelos de análisis y predicción, como la red combinada VGG-16-LSTM descrita en secciones anteriores.

3. Aplicación de la red neuronal VGG-16 y LSTM para la extracción de características en imágenes

Las imágenes generadas se introducen en un modelo VGG-16, que actúa como un extractor de características espaciales. Este modelo ha sido entrenado previamente en grandes conjuntos de datos como ImageNet [1], lo que le otorga la capacidad de identificar patrones visuales complejos, como bordes, texturas y formas, que son esenciales para capturar las características meteorológicas representadas en las imágenes.




Figura 3. Arquitectura VGG-16 [1]

Para este propósito, se elimina la capa final del modelo VGG-16, lo que permite utilizar únicamente sus capas convolucionales para la extracción de características [2]. Estas características consisten en representaciones numéricas de alta dimensión y encapsulan información espacial significativa que será procesada en la siguiente etapa del flujo de trabajo.

También, se normalizan las entradas para garantizar la compatibilidad con el modelo, y las características extraídas se almacenan como vectores que representan cada imagen, reduciendo la complejidad del conjunto de datos sin perder información esencial.

La secuencia de características espaciales extraídas de las imágenes se utiliza como entrada para una red neuronal LSTM (Long Short-Term Memory). Este tipo de red es ideal para modelar relaciones temporales debido a su capacidad para recordar información en intervalos largos de tiempo, algo crucial para capturar las dinámicas atmosféricas representadas en las imágenes [3], [4].




Figura 4. Arquitectura LSTM [3]

El modelo LSTM está diseñado para analizar cómo las características cambian con el tiempo, permitiendo identificar patrones temporales que podrían no ser evidentes al observar imágenes individuales [5]. Por ejemplo, la evolución de la cobertura de nubes o los cambios en la intensidad de aerosoles pueden ser capturados y modelados. La red se entrena utilizando secuencias de imágenes de longitud fija, alineadas con las marcas de tiempo originales, para maximizar la coherencia temporal. Además, se implementan técnicas como Dropout para evitar el sobreajuste y optimización con algoritmos como Adam para mejorar la convergencia del modelo [6].

4. Predicción de imágenes

El modelo VGG-16 y LSTM integrado genera imágenes predichas que completan las brechas en la secuencia temporal original. Estas predicciones están diseñadas para ser espacial y temporalmente consistentes con las imágenes originales, preservando las características clave de las condiciones atmosféricas.

El proceso de predicción comienza con la entrada de una secuencia de imágenes históricas, cuyas características se extraen mediante VGG-16 y se procesan con LSTM. A partir de estas secuencias, el modelo genera imágenes futuras que llenan los vacíos identificados en el conjunto de datos original. Las imágenes predichas se almacenan

con marcas de tiempo correspondientes y se evalúan tanto visual como cuantitativamente.

La evaluación incluye métricas como el error cuadrático medio (MSE) entre las imágenes reales y predichas, así como la validación cualitativa mediante inspección visual para confirmar que las predicciones reflejen fenómenos meteorológicos plausibles. Las imágenes resultantes son finalmente integradas en el conjunto de datos continuo, sirviendo como entrada para modelos posteriores de estimación del GHI.

III. RESULTADOS

En esta sección se presentan los resultados obtenidos al aplicar el modelo combinado de VGG-16 y LSTM para la predicción de imágenes satelitales en el producto ACMF del satélite GOES-16. Los resultados incluyen una evaluación cualitativa y cuantitativa del desempeño del modelo, destacando su capacidad para completar secuencias de imágenes faltantes y preservar la coherencia espacial y temporal.

III-A. Resultados de MSE en Entrenamiento y Validación

La Tabla II muestra los resultados obtenidos para diferentes configuraciones del modelo. Cada columna presenta los hiperparámetros utilizados, incluyendo el número de capas, neuronas, tasa de *dropout*, y el optimizador seleccionado. Los valores reportados corresponden al Error Cuadrático Medio (MSE) para las etapas de entrenamiento y validación.

III-B. Análisis de Resultados

A partir de los resultados de la Tabla II se puede establecer que:

III-B1. Modelo 1: El Modelo 1 utiliza una arquitectura con 4 capas LSTM y dos capas internas de 256 y 158 neuronas respectivamente. Este modelo no emplea regularización mediante *dropout* y utiliza el optimizador Adam. Los resultados muestran un MSE de 0.608 en el conjunto de entrenamiento y 0.588 en el conjunto de validación. El alto valor de MSE indica que el modelo tiene dificultades para ajustarse a los datos, posiblemente debido a la falta de regularización y una capacidad limitada para capturar patrones más complejos. La similitud entre los errores de entrenamiento y validación sugiere que el modelo no está sobreajustado, pero carece de la

capacidad suficiente para capturar dinámicas complejas de las secuencias temporales. Este modelo puede ser adecuado para problemas más simples o con datos menos complejos, pero su arquitectura limita su capacidad para generalizar sobre datos más intrincados. En la figura 5 se puede comparar el resultado de la imagen generada con la imagen real.




Figura 5. Modelo 1 - Imagen real vs Imagen predicha

III-B2. Modelo 2: El Modelo 2 introduce una arquitectura más compleja con 4 capas LSTM y dos capas internas con un mayor número de neuronas (1024 y 512). Además, implementa una tasa de *dropout* del 40 % para regularización y utiliza el optimizador Adam. Los resultados muestran un MSE de 0.036 en el conjunto de entrenamiento y 0.043 en el conjunto de validación. En la figura 6 se puede comparar el resultado de la imagen generada por este modelo con la imagen real.




Figura 6. Modelo 2 - Imagen real vs Imagen predicha

III-B3. Modelo 3: El Modelo 3 introduce un modelo de 8 capas donde las primeras 4 capas están compuestas por capas LSTM convolucionales que capturan características espaciales y temporales mas dos capas de normalización que ayudan a estandarizar las activaciones de las capas, mejorando

Tabla II
RESULTADOS DE MSE PARA DIFERENTES CONFIGURACIONES DE HIPERPARÁMETROS.

Modelo	Capas	Neuronas	Dropout	Optimizador	MSE train	MSE Val	Resolución imágenes de entrada	Cantidad de imagenes utilizadas
Modelo 1	4	256, 158	NA	Adam	0.608	0.588	450x450	80
Modelo 2	4	1024, 512	0.4	Adam	0.036	0.043	128x128	100
Modelo 3	8	128	NA	Adam	0.013	0.013	64x64	4270
Modelo 4	4	256, 128	NA	Adam	0.51	0.48	480x480	90

la estabilidad. Las siguientes cuatro capas toman los datos anteriormente procesados y los transforman para ser utilizados en la producción de las imágenes. El modelo compila con un optimizador adam, con una tasa de aprendizaje de 0.0001. Con este modelo se obtuvo un modelo con un mse de entrenamiento y validación de 0.013 aproximadamente.




Figura 7. Modelo 3 - Imagen real vs Imagen predicha

El uso de más neuronas permite al modelo capturar patrones temporales más complejos y mejorar el ajuste a los datos. La inclusión de *dropout* ayuda a evitar el sobreajuste, como lo indica la pequeña diferencia entre los errores de entrenamiento y validación. Este modelo muestra un desempeño significativamente mejor que el Modelo 1, lo que lo hace más adecuado para la tarea de predicción de imágenes satelitales. El Modelo 2 es más robusto y generaliza mejor los datos gracias a su arquitectura más compleja y la regularización incorporada.

III-B4. Modelo 4: El Modelo 4 nuevamente cuenta con 4 capas y una cantidad de neuronas de 256 y 158 para las capas LSTM y la resolución de las imágenes es de 480X480, la arquitectura es muy similar a la del modelo 1, sin embargo este modelo se utilizó un sistema operativo Linux ejecutado en una workstation equipada con un procesador Intel Core i9-13900KF, 32 núcleos virtuales, una velocidad máxima de 5.8 GHz y 125 GiB de memoria RAM. Este hardware robusto permitió manejar cálculos complejos y procesar grandes volúmenes de datos de manera eficiente. Además, el uso de GPUs resultó esencial para paralelizar operaciones matemáticas y acelerar el entrenamiento de las redes neuronales profundas. Este entorno no solo garantizó tiempos razonables de ejecución, sino que también aseguró la viabilidad del modelo para proyectos futuros que involucren mayores volúmenes de datos o diferentes ubicaciones geográficas. En la figura 8 se puede comparar los resultados cuando se puede entrenar un modelo con un poco más de procesamiento de máquina.

IV. CONCLUSIONES

En este trabajo, se desarrolló un modelo combinado de redes neuronales VGG-16 y LSTM para la predicción de imágenes satelitales del producto ACMF del satélite GOES-16. Este modelo tiene como objetivo completar las brechas en secuencias temporales de imágenes, permitiendo mejorar la continuidad y consistencia de los datos utilizados en tareas de predicción meteorológica y análisis ambiental.




Figura 8. Modelo 4 - Imagen real vs predicha

IV-A. Principales hallazgos

- El modelo logró capturar patrones espaciales y temporales significativos en las imágenes satelitales. Los resultados cuantitativos mostraron que configuraciones con arquitecturas más complejas y técnicas de regularización, como el *dropout*, producen valores de MSE más bajos, destacando la robustez y generalización del modelo.
- La evaluación visual indicó que las imágenes predichas reflejan correctamente las tendencias globales de movimiento y cobertura de nubes observadas en las imágenes reales. Aunque se identificaron ligeras diferencias en detalles locales, los patrones generales se preservaron adecuadamente.
- La combinación de la extracción de características espaciales mediante VGG-16 y el modelado de dinámicas temporales con LSTM resultó ser efectiva para tareas de predicción de imágenes en series temporales.

IV-B. Implicaciones del estudio

Este modelo es especialmente útil para completar conjuntos de datos incompletos en aplicaciones que requieren secuencias temporales continuas, como la estimación de irradiación solar y el análisis de dinámicas meteorológicas. Además, la metodología puede adaptarse a otros productos del satélite GOES-16 o datos similares de otros satélites.

IV-C. Limitaciones y futuros trabajos

Aunque el modelo presentó un buen desempeño general, se identificaron algunas limitaciones:

- Las imágenes predichas tienden a suavizar los detalles más finos en áreas de alta densidad de nubes. Esto sugiere que podrían ser necesarias arquitecturas más avanzadas o el uso de datos adicionales para mejorar la precisión en estas regiones.
- El costo computacional del entrenamiento del modelo aumenta significativamente con configuraciones más complejas, lo que podría ser una limitación en entornos con recursos computacionales restringidos.
- La evaluación se centró en un subconjunto del producto ACMF. Futuros trabajos podrían explorar la generalización del modelo a otras variables y productos del satélite.

IV-D. Contribuciones

Este estudio contribuye al campo del análisis de datos satelitales al:

- Proponer un enfoque innovador que combina VGG-16 y LSTM para la predicción de imágenes en series temporales.
- Validar la capacidad del modelo para completar brechas en datos satelitales de alta resolución.
- Proporcionar una metodología replicable y adaptable para otras aplicaciones relacionadas con el análisis de imágenes satelitales.

En conclusión, el modelo desarrollado demuestra su eficacia para completar secuencias temporales de imágenes satelitales, destacando su potencial en aplicaciones relacionadas con el monitoreo ambiental, la predicción meteorológica y el análisis de datos climáticos. Los hallazgos de este trabajo sientan las bases para futuras investigaciones y mejoras en la predicción de imágenes y series temporales complejas.

El análisis sugiere que la combinación de una arquitectura más compleja y la regularización adecuada resulta en un mejor desempeño para la tarea de predicción de imágenes. Sin embargo, es importante considerar que el Modelo 2 podría requerir más recursos computacionales debido al mayor número de parámetros. Esto podría ser una limitación en aplicaciones donde el tiempo de entrenamiento o la capacidad de hardware son factores críticos.

Por otro lado el modelo 3 sugiere utilizar capas LSTM convolucionales para aprovechar las ventajas de captura de rasgos espaciales de las capas convolucionales y la captura temporal de las LSTM.

En trabajos futuros, sería interesante explorar:

- Variaciones en la tasa de *dropout* para encontrar un balance óptimo entre generalización y ajuste.
- El impacto de otros optimizadores, como RMSProp o SGD, en arquitecturas complejas.
- Evaluaciones con conjuntos de datos más amplios para probar la escalabilidad de los modelos.

Esta comparación permite identificar el Modelo 2 como una opción más adecuada para este problema específico, debido a su bajo error y buena capacidad de generalización.

REFERENCIAS

- [1] K. Simonyan and A. Zisserman, "Very deep convolutional networks for large-scale image recognition," *arXiv preprint arXiv:1409.1556*, 2014.
- [2] F. Chollet, *Deep Learning with Python*. Manning Publications, 2018.
- [3] S. Hochreiter and J. Schmidhuber, "Long short-term memory," *Neural computation*, vol. 9, no. 8, pp. 1735–1780, 1997.
- [4] F. A. Gers, J. Schmidhuber, and F. Cummins, "Learning to forget: Continual prediction with lstm," *Neural computation*, vol. 12, no. 10, pp. 2451–2471, 2000.
- [5] J. Donahue, L. Anne Hendricks, S. Guadarrama, M. Rohrbach, S. Venugopalan, K. Saenko, and T. Darrell, "Long-term recurrent convolutional networks for visual recognition and description," *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 2625–2634, 2015.
- [6] D. P. Kingma and J. Ba, "Adam: A method for stochastic optimization," *arXiv preprint arXiv:1412.6980*, 2015.